
Proyecto I

CRISP-DM: Metodología para
Ciencia de datos



**Universidad
de Medellín**
Ciencia y Libertad

La necesidad de una metodología

Problema:

- Garantizar que tu proyecto va llegar a un feliz término
- Definir una metodología estándar y repetible
- Traducir problemas de negocio a tareas de ciencia de datos

Cross-Industry Standard Process for Data Mining (CRISP-DM)

- Creado a finales de los 90
- Creado por el consorcio Daimler-Chrysler, SPSS, NCR y OHRA
- Es una de las metodologías más populares
- Robusto
- Sistemático.
- Versátil
- Repetible

Comparación con otras metodologías

KDD

SEMMA

CRISP-DM

Pre KDD	-----	Business understanding
Selection	Sample	Data Understanding
Pre processing	Explore	
Transformation	Modify	Data preparation
Data mining	Model	Modeling
Interpretation/Evaluation	Assessment	Evaluation
Post KDD	-----	Deployment


Enfoque académico

Orientado a herramienta

Orientado a negocio

El ciclo CRISP-DM

Iteración como eje central



Fuente:

<https://www.iic.uam.es/innovacion/metodologia-crisp-dm-ciencia-de-datos/>

Fase 1: Comprensión del Negocio

- Entender qué problema de negocio se quiere resolver.
- **Traducir** a **objetivos** de ciencia de datos y **accionables** (ej. “incrementar retención en 5%”).
- Tener a la gente de negocio del lado es crucial para esto.

Ejemplos

- Negocio: reducir pérdida de clientes (churn).
- Data Mining: construir un modelo que prediga la probabilidad de churn.
- Éxito: que el modelo ayude a reducir el churn real en un 10% en 3 meses.

Fase 1: Comprensión del Negocio

Entregables típicos:

- Declaración del problema y métricas de éxito.
- Evaluación de recursos, limitaciones y riesgos.
- Plan preliminar del proyecto.

Actividad (2-3 personas):

Piensen en sus proyectos y formulen el objetivo de ciencia de datos correspondiente.

Recolección de datos

Utilizar datos de una fuente confiable, ya que afectarán directamente el resultado de su modelo. Los datos de calidad son relevantes, contienen muy pocos valores faltantes y repetidos, y representan adecuadamente las diversas subcategorías/clases presentes.



<https://www.datos.gov.co/>



<https://archive.ics.uci.edu/datasets>

Google Trends

<https://trends.google.com/trends/>

Fase 2: Comprensión de los Datos

- **Recolectar** datos disponibles y entender su contenido.
- Detectar **calidad, volumen, variedad** y **sesgos**.
- Generar **hipótesis** iniciales.

Ejemplos





- Dataset de clientes: edad, ingresos, frecuencia de compra, tiempo de relación.
- Detectas que el 30% de los ingresos faltan y los clientes jóvenes están subrepresentados.

Fase 2: Comprensión de los Datos

Exploración inicial

Visuales sugeridos:

- Histogramas, boxplots, correlaciones.
- Conteo de valores nulos, cardinalidad de variables categóricas.
- Análisis de outliers.



Fase 2: Comprensión de los Datos

Entregables

- **Informe descriptivo** de los datos.
- **Problemas** detectados y posibles causas.
- **Hipótesis** para la siguiente fase.

Fase 3: Preparación de los Datos


- Construir el **dataset** final listo para modelar.
- **Limpiar, transformar, integrar y seleccionar** datos.

Tareas clave:

- ◆ Imputación de nulos.
- ◆ Codificación (one-hot, label encoding).
- ◆ Escalamiento de variables.
- ◆ Selección de features.
- ◆ Creación de nuevas variables (Feature engineering).

Fase 3: Preparación de los Datos


Feature engineering



Fase 3: Preparación de los Datos

Entregables:

- Dataset preparado (train/test).
- Documentación del proceso de transformación.
- Justificación de las variables elegidas.

 pandas matplotlib plotly statsmodels NLTK
Express Your Creativity NumPy

Fase 3: Preparación de los Datos

Actividad (2-3 personas):

¿Qué harías con estos datos? (nulos, outliers, formatos inconsistentes)''

ID	Fecha	Precio	Cliente	Ciudad
1	2023/12/05	59.99	Juan P.	Bogotá
2	12-06-23	NaN	Maria G	Bta
3	2023/12/07	-15		Medellin
4	2023/12/05	89.90	Carlos S.	bogotá


Fase 4: Modelado

- Seleccionar el **algoritmo** más apropiado según el tipo de problema y datos.
- **Métricas adecuadas** para el modelo (clasificación, regresión, segmentación de imágenes, etc)
- **Optimizar modelo** e identificar en base a que optimizar (accuracy, f1-score, etc).

Ejemplo práctico (Caso churn)

- **Modelos candidatos:** regresión logística, árbol de decisión, random forest.
- Validación cruzada (k=5).
- **Métricas:** F1 = 0.72 (logística), 0.76 (árbol), 0.81 (RF).
- **Elección final:** Random Forest por mejor balance precisión/interpretabilidad.

Fase 4: Modelado



XGBoost



Fase 4: Modelado

Entregables

- Modelos entrenados y comparados.
- Parámetros y resultados de validación.
- Gráficos de importancia de variables.

Discusión (5 min)

¿Qué pesa más: precisión o interpretabilidad?

Fase 5: Evaluación

- Verificar si el modelo cumple los **objetivos** de negocio, no solo métricas técnicas.
- Analizar errores y sesgos.

Métricas

- Clasificación: Accuracy, Recall, Precision, F1, AUC.
- Regresión: RMSE, MAE, R^2 .
- Visuales: matriz de confusión, curva ROC, Lift chart.

Ejemplo

Modelo de churn: Recall = 0.88 → bueno para detectar clientes que se irán, aunque tenga falsos positivos.

Comunicar los resultados del modelo

- Después de construir la solución es crucial **compartir** tus resultados a los stakeholders
- Procura saber a **quién** va dirigida la presentación, por ejemplo, a alguien de negocio, en general, no le importa los algoritmos que usaste, más bien están interesados en cómo los resultados pueden ayudar a propulsar los objetivos del negocio, en cambio, una persona más técnica verá mejor que expliques si usaste cierto modelo y cómo tuneaste hiperparámetros
- Un buen **storytelling** te ayudará a **mostrar** cómo los resultados del modelo ayudan a resolver el problema de negocio. Procura comunicarte de manera sencilla y directa, también usa ayudas visuales.

Fase 6: Despliegue del modelo



¿Cómo vamos a disponibilizar el modelo para que sea accesible a un usuario final?

En tiempo real

- Las predicciones son generadas y devueltas al usuario en el menor tiempo posible después de recibir la solicitud.
- Menor latencia.
- Consume recursos constantemente.

Predicción por lotes

- Se procesa gran cantidad de datos de entrada y el modelo genera las predicciones en forma asincrónica (la respuesta no es inmediata)
- Mayor latencia.
- Procesamiento diario, semanal, mensual, etc.

Mantenimiento de los modelos

¿Cómo sabemos que el modelo es acorde al negocio y sigue siendo funcional?

1. Evaluar el rendimiento del modelo para detectar posibles desviaciones ej: data drift.
2. Establecer estrategias de labelling en los datos y evaluar el performance.
3. Establecer un protocolo para identificar los errores de predicción y corregir si es posible.
4. Planificar ciclos de re-entrenamiento para adaptar el modelo a nuevos datos y tendencias emergentes. (La automatización de los pipelines puede ser de gran utilidad.)



Definición de métricas: KPIs



- ¿Cómo se desea evaluar los resultados obtenidos?
- Paso crucial para definir el avance e impacto del proyecto
- Un proyecto de DS no es más que un proceso en el que se intentará **optimizar** “algo”, si ese algo no se tiene definido muy probablemente estaremos gastando energía en cosas que no nos ayudarán con nuestro objetivo

Preguntarse:

- ¿Es mi métrica muy general?, ¿Realmente mide lo que deseo medir?
- ¿Cómo se afecta la métrica por otros factores? ¿Tengo control sobre esos factores?
- ¿Qué tan difícil es medir mi KPI?, ¿Hay fuentes para construirla?
- ¿Que periodicidad tendrá dicha métrica?
- ¿Los KPIs estarán relacionados con la métricas para optimizar el modelo?
- ¿Los *stakeholders* están de acuerdo con esta métrica?

Recordar: ¡Esto es un proceso iterativo!

Caso de ejemplo: E-commerce de moda

Problema: clientes no recompran.

Datos: historial de compras, género, edad, visitas web.

Objetivo: aumentar recompra un 15%.

Fases:

1. Negocio: identificar clientes con riesgo de abandono.
2. Datos: 10.000 clientes, 25 variables.
3. Preparación: imputación y creación de variable “días desde última compra”.
4. Modelado: Random Forest → AUC = 0.84.
5. Evaluación: cumple objetivo.
6. Despliegue: dashboard + campaña de retención automática.

¿Qué riesgos ven en este proyecto? ¿Dónde podría fallar?

Cierre y Reflexión

Beneficios

- Marco ordenado y claro.
- Centrado en el negocio.
- Reutilizable en cualquier industria.

Limitaciones

- No contempla automatización ni MLOps.

Cierre y Reflexión

Conclusión

- CRISP-DM no es solo una secuencia técnica, sino una forma de pensar proyectos de datos.
- El éxito depende de la colaboración interdisciplinaria
- La iteración es crucial.

Pregunta final

¿En qué fase creen que fallan más los proyectos reales? ¿Por qué?



Gracias

